

OPTIMIZACIÓN DEL RENDIMIENTO DE LOS CULTIVOS DE MAÍZ BASADO EN CLUSTERWISE LINEAR REGRESSION Y METAHEURÍSTICAS



Anteproyecto de Trabajo de Grado

Ing. Germán Homero Morán Figueroa

Director: PhD. Carlos Alberto Cobos Lozada

**Universidad del Cauca
Facultad de Ingeniería Electrónica y Telecomunicaciones
Departamento de Sistemas
Maestría en Computación
Grupo de Investigación y Desarrollo en Tecnologías de la Información (GTI)
Área de interés en Sistemas Inteligentes y Gestión de la Información
Popayán, Agosto del 2023**

TABLA DE CONTENIDO

1	PLANTEAMIENTO DEL PROBLEMA	3
2	JUSTIFICACION DEL PROBLEMA	5
3	APORTES	6
4	ESTADO DEL ARTE	7
4.1	Estudios referentes a la predicción del rendimiento del maíz.....	7
4.2	Estudios relacionados con CLR	11
5	OBJETIVOS	12
5.1	Objetivo general	12
5.2	Objetivos específicos.....	13
6	HIPOTESIS	13
7	ACTIVIDADES Y CRONOGRAMA	15
7.1	Actividades	15
7.2	Cronograma de actividades	18
8	RECURSOS, PRESUPUESTO Y FUENTES DE FINANCIACIÓN	18
9	CONDICIONES DE ENTREGA	19
10	REFERENCIAS BIBLIOGRÁFICAS	20

INDICE DE FIGURAS

Figura 1: Metodología CRISP-DM.....	16
-------------------------------------	----

INDICE DE TABLAS

Tabla 1: Cronograma de actividades	18
Tabla 2: Presupuesto del proyecto.....	19

LISTA DE ACRÓNIMOS

ANN	<i>Artificial Neural Network, Red Neuronal Artificial.</i>
CE	<i>Coefficient Efficiency, Coeficiente de Eficiencia.</i>
CLR	<i>Clusterwise Linear Regression, Regresión Lineal por Agrupaciones.</i>
GWO	<i>Grey Wolf Optimizer Algorithm, Algoritmo de Optimización del Lobo Gris.</i>
GWRFR	<i>Geographically Weighted Random Forest Regression, Regresión Forestal Aleatoria Ponderada Geográficamente.</i>
IA	<i>Artificial intelligence, Inteligencia Artificial.</i>
IoT	<i>Internet of Things, Internet de las Cosas.</i>
LR	<i>Linear Regression, Regresión Lineal.</i>
MAE	<i>Mean Absolute Error, Error Absoluto Medio.</i>
MAPE	<i>Mean Absolute Percentage Error, Error Porcentual Absoluto Medio.</i>
ML	<i>Machine Learning, Aprendizaje Automático.</i>
MLR	<i>Multiple Linear Regression, Regresión Lineal Múltiple</i>
RMSE	<i>Root Mean Square Error, Error Cuadrático Medio.</i>
SA	<i>Simulated Annealing, Recocido Simulado.</i>
SSF	<i>Site-Specific Farming, Agricultura Específica Por Sitio.</i>

1 PLANTEAMIENTO DEL PROBLEMA

El maíz es considerado el segundo cultivo del mundo por su producción solo superado por el trigo, tiene gran importancia económica a nivel mundial dada su amplia variedad de uso ya sea como alimento humano, alimento para especies animales o como fuente de un gran número de productos industriales [1],[2]. En Colombia el maíz es el tercer producto con mayor demanda, solo después del café y del arroz, aportando el 9% de energía diaria en la dieta de todos los colombianos, este cultivo en 2021 representó el 13% de la producción agrícola del país donde numerosas familias campesinas se dedican a esta actividad [3].

Actualmente, en el país existen 2 sistemas de producción de maíz, el tecnificado y el tradicional. El sistema tecnificado se caracteriza por monocultivos con más de 5 Ha (hectáreas) que cuentan con todos los recursos y tecnologías basadas en la mecanización para la preparación de suelos, uso de semillas mejoradas, entre otros. En Colombia, este sistema representa el 48% del área destinada para la producción de maíz, con una producción de 2.43Mt (megatoneladas) y un rendimiento promedio de 5.64 Tn/Ha (toneladas por hectárea) para el periodo 2021-2022. Por su parte el sistema tradicional se caracteriza por áreas de siembra menores a las 5 Ha en donde el cultivo se basa en el uso de una amplia diversidad de variedades de semillas nativas, la no utilización de híbridos ni tecnología mecanizada, debido a las dificultades económicas para su acceso. Sin embargo, a pesar de contar con mayor cantidad de área destinada a la siembra, los niveles de producción son muy bajos comparados con los sistemas tecnificados. En el sistema tradicional la producción está alrededor de 0.66 Mt y un rendimiento promedio de 2.24 Tn/Ha [4].

Según datos de la Federación Nacional de Cultivadores de Cereales y Leguminosas (FENALCE) en el año 2021 Colombia importó 6 Mt de maíz y produjo únicamente 1.79 Mt [4]. Este hecho muestra que los niveles de productividad en los últimos años han incrementado considerablemente pero aún existe una brecha muy grande entre importación y producción. Teniendo en cuenta la importancia de la producción de maíz a nivel nacional e internacional, los agricultores colombianos tienen el desafío de aumentar la tasa de productividad cada año. Según la experiencia de los cultivadores, algunos de los aspectos más relevantes que afectan los niveles de producción de maíz son el exceso de nitrógeno, el drenaje del cultivo, la variación del clima, la inadecuada fertilización del terreno, el mal manejo de las prácticas tradicionales, el poco acompañamiento técnico, entre otras [5].

Hoy en día, debido al Big Data es posible desarrollar soluciones tecnológicas y modelos estadísticos o de inteligencia artificial (IA) que permitan aprovechar todo el volumen de información y datos recolectados sobre los procesos y ciclos completos que sufren las plantas desde la siembra hasta la cosecha, para generar propuestas de gran valor que puedan beneficiar la toma de decisiones [6]. A nivel de predicción del rendimiento de los cultivos ha habido grandes esfuerzos en caracterizar diferentes productos como el arroz, la haba de soja, el trigo, el maíz, la caña de azúcar, entre otros, aplicando diferentes técnicas de minería de datos e inteligencia artificial [7],[8],[9].

Cada uno de estos estudios se caracteriza porque se definen diferentes variables que pueden afectar determinados cultivos. Sin embargo, definir los factores que más influyen en los niveles de productividad del maíz resulta difícil, debido a la cantidad de variables que pueden afectar directa e indirectamente la producción de este como, por ejemplo: genotipo, clima, prácticas de manejo de agua, humedad del suelo, nutrientes del suelo, entre otros. De lo anterior han surgido investigaciones que buscan entender las variables y las relaciones más relevantes en los cultivos, indicando que cada vez que el agricultor realiza una siembra hay un evento único [10], ya que es un experimento totalmente nuevo que se puede manipular y hacer seguimiento en todo su ciclo de vida. Si se tiene el registro histórico de un número significativo de estos eventos y se realiza la implementación de un enfoque de modelado estadístico tradicional (generación de un modelo matemático basado en datos) o modelado basado en algoritmos de Inteligencia artificial (generación de un modelo matemático basado en datos sin hacer suposiciones sobre la distribución y comportamiento de los datos) se puede identificar ciertas tendencias y relaciones en los datos para proveer información a los productores sobre cómo elegir técnicas para el manejo adecuado de sus cultivos.

Por otro lado, la agricultura específica por sitio (SSF, *Site Specific Farming*) juega un papel crucial en la caracterización de los cultivos porque permite realizar prácticas agronómicas de acuerdo con las condiciones espaciales y temporales del sitio donde se cultiva para obtener el mayor rendimiento. Las fincas dedicadas a la producción de maíz en el territorio nacional son altamente heterogéneas, se necesita una gran cantidad de datos de diferentes eventos para tratar de entender esa variabilidad; ya que aprender del conocimiento colectivo es mucho más enriquecedor que trabajar con eventos por separado. En la literatura, existen investigaciones donde se han usado algoritmos de agrupamiento (clustering) para identificar las mejores prácticas de manejo basándose en agrupación de atributos; como por ejemplo en [11] donde se propone una técnica de agrupamiento para predecir el rendimiento de cultivos basada en la maximización de la probabilidad de proximidad (PLMDC, *Proximity Likelihood Maximization Data Clustering*) o en [12] donde se realiza un plan de fertilización por sitio de acuerdo a las características del suelo. Además, en [13],[14] se han probado diferentes técnicas de ML como: árboles de decisión, bosques aleatorizados (random forest), máquinas de soporte vectorial (support vector machines, SVM), redes neuronales, series de tiempo, entre otros, logrando óptimos resultados. En este sentido en el presente estudio se busca implementar y probar diferentes técnicas y algoritmos de ML que permitan predecir el rendimiento del cultivo de maíz, como también se busca integrar el enfoque Clusterwise Linear Regression o CLR (análisis por agrupaciones y modelos de regresión), dadas las condiciones de la SSF, y los buenos resultados logrados en otros campos de aplicación como en [15], donde se propone el uso de CLR para predecir el índice de servicio del pavimento asociado a las al clima, la carga de transporte y características propias del pavimento.

Con base en lo anterior se plantea la siguiente pregunta de investigación: ¿Cómo adaptar diversos modelos de ML, entre ellos, Clusterwise Linear Regression (CLR) para predecir el rendimiento del maíz en el departamento de Córdoba?

La adaptación del enfoque CLR se realizaría con base en las cuatro grandes variables que se implican en el rendimiento de un cultivo como el del maíz, a saber: la genética de las semillas, el clima, las características del suelo y las prácticas de manejo o cultivo. Como se mencionó previamente, es muy importante para un agricultor identificar las prácticas de manejo que le permitan obtener el mayor rendimiento dentro de ciertas restricciones de costos, en este sentido, las metaheurísticas toman un papel protagónico, ya que permiten tomar el modelo CLR u otro modelo de predicción y sujeto a unas restricciones basado en ciertas condiciones de genética, clima, suelo, prácticas de manejo y costos se encuentre una solución que permita aumentar el rendimiento de la granja. Por lo tanto, en esta investigación se busca explorar el uso de dos metaheurísticas reconocidas en el estado del arte por sus significativos resultados en problemas de optimización con características similares (espacio de búsqueda mixto con restricciones). La primera de estado simple, el Recocido Simulado (SA, *Simulated Annealing*) [16], dada su gran capacidad para escapar de óptimos locales, además, según [17] las medidas de rendimiento de un algoritmo metaheurístico se pueden generalizar en 2 grandes categorías eficiencia y eficacia. Algunos algoritmos son más eficientes que otros para un problema específico, sin embargo, SA presenta grandes beneficios en cuanto a complejidad computacional, velocidad y tasa de convergencia hacia un óptimo global respecto a otros algoritmos, además se considera fácil de adaptar y personalizar. Por otra parte, el segundo algoritmo seleccionado es el Algoritmo de Optimización del Lobo Gris (GWO, *Grey Wolf Optimizer Algorithm*) [18]; aunque existen muchos algoritmos de inteligencia de enjambre que imitan el comportamiento de caza y búsqueda de animales, GWO simula una jerarquía de liderazgo interno de lobos que en el proceso de búsqueda hace que la posición de la mejor solución puede evaluarse de manera integral mediante tres soluciones, a diferencia de otros algoritmos de inteligencia de enjambre como las colonias de abejas (ABC, *Artificial Bee Colony*) o la búsqueda cucú (CS, *Cuckoo Search*), donde la mejor solución es liderada por una única solución [19]. Algunas de las ventajas de utilizar este algoritmo son su velocidad de búsqueda y la alta precisión de sus resultados en diferentes problemas. Además se caracteriza porque puede disminuir en gran medida la probabilidad prematura de caer en un óptimo local, a través de un adecuado balance entre la exploración y explotación del vecindario.

Con base en lo anterior se plantea una segunda pregunta de investigación: ¿Cómo adaptar las metaheurísticas de Recocido Simulado y el Algoritmo del Lobo Gris para recomendar las prácticas óptimas de cultivo para condiciones específicas de las fincas (granjas) en el departamento de Córdoba y cuál de estas reporta los mejores resultados?

2 JUSTIFICACION DEL PROBLEMA

La presente propuesta de trabajo de grado en modalidad de investigación es pertinente en el contexto de la predicción del rendimiento de cultivos y se enmarca en las áreas de interés de sistemas inteligentes y de gestión de la información del grupo de investigación y desarrollo en Tecnologías de la Información (GTI) de la Universidad del Cauca. Tener conocimiento previo sobre el rendimiento de cualquier cultivo es fundamental ya que ayuda a los agricultores en la toma de decisiones y en la planificación de las cosechas futuras, evitando sobrecostos y pérdidas durante las nuevas siembras. Según FENLACE Colombia

es el séptimo país en el mundo con los mayores niveles de producción de maíz, en los últimos 50 años la producción y demanda de este producto ha incrementado en un 76%, además, se espera que entre el 2021 y el 2030 la producción crezca en un 6% y la demanda en un 9%. Según las estadísticas de FENALCE para el año 2021 se destinaron 361.626 Ha para la producción de maíz blanco y amarillo distribuidos en todo el territorio nacional [20].

Por otro lado, el departamento de Córdoba fue el segundo departamento con mayor nivel de productividad sólo superado por Tolima, alcanzando una productividad de 201.990 Tn, no obstante, a nivel de rendimiento de cultivo se ubica en el puesto 10 logrando un promedio de 3,54 Tn/Ha. A pesar de que actualmente en el departamento se tienen grandes áreas destinadas a la producción de maíz los niveles de rendimiento no reflejan los niveles deseados, por tal motivo es de gran importancia desarrollar soluciones que permitan a los agricultores mejorar los niveles de productividad y apoyar la toma de decisiones en cuanto a la planificación de actividades, infraestructura, materiales requeridos, negociaciones, riesgo y pérdidas debido a fenómenos externos como la presencia de plagas y enfermedades, entre otros. Las predicciones precisas permiten una buena planificación logrando reducir costos y aumentar los niveles de rentabilidad.

A la fecha se han realizado varias investigaciones para determinar el rendimiento de cultivos, algunos mediante el uso de big data e inteligencia artificial (IA, *Artificial intelligence*) apoyados en tecnologías como la internet de las cosas (IoT, *Internet of Things*), robótica, entre otros. Estas propuestas están enfocadas en diferentes cultivos como la soya, el arroz, el algodón, el maíz y la mayoría incluyen información relacionada a variables como el clima y el suelo, sin tener en cuenta variables como las prácticas de manejo y el tema de la agricultura específica por sitio que permite caracterizar las fincas y zonas de cada municipio teniendo en cuenta más variables de su contexto. En esta investigación se aborda un enfoque matemático estadístico apoyado en las ciencias de la computación para construir algoritmos de machine learning que permitan modelar el comportamiento de los datos e identificar tendencias que permita predecir los niveles de producción del maíz con base en datos históricos recolectados de las diferentes fincas y municipios del departamento de Córdoba.

3 APORTES

Los aportes de este proyecto desde la perspectiva de investigación se centran en buscar nuevo conocimiento relacionado con el diseño, aplicación y evaluación de un algoritmo basado en el enfoque CLR para la predicción del rendimiento del cultivo de maíz. En cuanto a la optimización de las prácticas de cultivo se espera investigar en la adaptación de las metaheurísticas de recocido simulado y la optimización del lobo gris.

Desde la perspectiva de innovación se espera desarrollar un modelo utilizable, siguiendo los lineamientos establecidos en la metodología CRISP-DM que abarca desde la comprensión de datos hasta el despliegue. Además, se busca, desarrollar un pipeline con todo el proceso de extracción, transformación y carga (ETL), modelado, evaluación y despliegue, con el objetivo de que pueda ser replicado para varios experimentos donde se

incluyan diferentes variables que puedan afectar el rendimiento del cultivo de maíz. Finalmente, el modelo será desplegado mediante una aplicación software que sirva como principal herramienta de apoyo para los técnicos y agricultores de maíz colombianos en la toma de decisiones, además, se espera que su uso pueda ser replicado a nivel internacional y sirva como base para futuras investigaciones.

Desde la perspectiva social, se espera que el uso de los modelos obtenidos beneficie a los agricultores de maíz al interior del departamento de Córdoba, al permitirles conocer y replicar las mejores prácticas que inciden en los niveles de producción, gracias a la identificación y agrupación de zonas de cultivo con características similares en las que se llevan a cabo distintas prácticas de manejo agronómico sin importar la distancia geográfica de dichas zonas. Finalmente, a partir de lo anterior es posible generar una solución tecnológica de alto impacto que se enmarca en el campo de la agricultura y su ejecución es viable en cuanto a tiempo, aplicación y recursos.

4 ESTADO DEL ARTE

La estadística e inteligencia artificial son conceptos ampliamente utilizados en la industria tecnológica dada su relevancia en el mundo moderno debido al auge del Big Data y la industria 4.0¹. Cada día se requieren nuevas soluciones capaces de analizar grandes volúmenes de datos y tomar decisiones, es ahí cuando estos conceptos (estadística, IA) toman gran relevancia porque pueden ayudar a las organizaciones a ser más competitivas y productivas. A continuación, se presentan los trabajos de investigación más relevantes relacionados con el caso de estudio del cultivo de maíz y las diferentes técnicas y algoritmos utilizados para abordar la predicción del rendimiento. Los estudios se encuentran ordenados en orden cronológico de acuerdo con el año de publicación. Luego y también en orden cronológico se muestran estudios relacionados con CLR en diferentes áreas de aplicación.

4.1 Estudios referentes a la predicción del rendimiento del maíz

En 2022 [21], se realizó un estudio para predecir el rendimiento de maíz planteando un modelo de regresión forestal aleatoria ponderada geográficamente (GWRFR, *Geographically Weighted Random Forest Regression*) en el cinturón de maíz². Se analizó el rendimiento mediante 5 algoritmos de aprendizaje automático (ML, *Machine Learning*) no espaciales, regresión lineal múltiple (MLR), regresión de mínimos cuadrados parciales (PLSR), regresión por vectores de soporte (SVR), regresión de árbol de decisión (DTR) y regresión de bosque aleatorio (RFR), donde se incluyen 5 fuentes de datos referentes a capas de tierra de cultivo, índices de vegetación (NDVI y EVI), producción primaria bruta (PPB), datos climáticos y datos del suelo. Para la predicción del rendimiento se utilizó la técnica de validación cruzada con 10 folders. El estudio permite realizar la comparación entre el modelo GWRFR versus los otros modelos no espaciales, concluyendo que el

¹ La **industria 4.0** hace referencia a la digitalización de los procesos productivos que combina técnicas avanzadas de producción y operaciones con tecnologías inteligentes que se integrarán en las organizaciones, las personas y los activos.

² El **cinturón de maíz** es una región del medio oeste de los Estados Unidos que desde la década de 1850 ha dominado la producción de maíz.

modelo propuesto logra un R^2 y un RMSE mejor en comparación con los modelos tradicionales, además. El modelo propuesto en este artículo aborda la no estacionariedad espacial de los cultivos.

También en 2022 [22], se planteó un modelo para predecir el rendimiento del cultivo de maíz donde se utiliza todo el espectro de promedios meteorológicos en distintas ventanas de tiempo estacionales. Esta investigación se desarrolló en Alemania utilizando conjuntos de datos de producción que van desde 1999 hasta 2020 referentes a 10 diferentes especies de maíz. Además, se utilizaron datos meteorológicos mensuales e información de rendimiento a nivel de distrito. En este caso de estudio se desarrolló el algoritmo ABSOLUT que utiliza múltiples regresiones lineales para cada subunidad espacial (distrito). Este algoritmo tiene la particularidad que involucra diversas características meteorológicas agregadas en diferentes instantes de tiempo como, por ejemplo: la suma de las precipitaciones en los meses de diciembre, enero y febrero antes de la cosecha en un año arbitrario permitiendo hacer selección de atributos y obtener las mejores características que se utilizarán en cada modelo.

El algoritmo ABSOLUT tiene 5 fases. Las 3 primeras fases hacen referencia a la selección de características para cada distrito mediante pruebas de correlación y procesos optimización para reducir la carga computacional, mientras que las fases 4 y 5 permiten realizar la predicción del rendimiento del cultivo con base en las ecuaciones de los modelos de regresión. Para este estudio se seleccionaron 3 variables climáticas principales: temperatura promedio, precipitación y duración de las insolaciones, con base en estas tres variables se generaron 145 características meteorológicas para caracterizar modelos en diferentes áreas. Los autores concluyen que el desempeño del algoritmo ABSOLUT es bueno en comparación con otras herramientas nacionales de predicción de rendimiento de cultivos como la usada por la Oficina Federal de Estadística de Alemania (DESTATIS, *Statistisches Bundesamt*) y el Centro Común de Investigación (JRC) de la Comisión Europea (con su actividad MARS). Sin embargo, resaltan que otro factor relevante que puede afectar los rendimientos son los extremos meteorológicos (olas de calor, precipitación durante las tormentas, entre otros) que no se tuvieron en cuenta en la investigación, además de factores no meteorológicos como el estado del riego, fertilizantes y las condiciones agrícolas generales.

En 2021 [23], se presenta un modelo para estimar la predicción del rendimiento de maíz a nivel de los condados en EE.UU; este modelo estima 3 componentes independientes, genética, ambiente y manejo de cultivo. El objetivo de esta investigación no solo es predecir el rendimiento del cultivo, sino también busca dar explicaciones relacionadas con la variabilidad temporal y espacial en relación con el clima, el suelo y las variables de manejo. En esta investigación se utilizaron 78,169 registros referentes a 2,649 condados, los datos utilizados abarcan desde el año 1980 a 2019. La información referente al rendimiento y las prácticas de manejo se obtuvo del servicio nacional de agricultura de estados unidos (USDA)[24], mientras que la información del clima se recolectó directamente de la

aplicación de la Nasa EarthData [25]. A nivel general algunas de las variables más relevantes que se tuvieron en cuenta para el modelado son:

- aws: almacenamiento de agua disponible expresado en mm (milímetros). Hace referencia al volumen de agua que puede almacenar el suelo,
- tka: espesor de los componentes en el suelo, expresado en cm para el cálculo del almacenamiento de agua disponible,
- soc: estimación del stock de carbono orgánico del suelo,
- rootznaws: estimación del almacenamiento de agua disponible en la zona de raíces expresada en mm,
- dayl: duración del período de luz diurna en segundos por día,
- prcp: precipitación total diaria en mm por día y
- srad: densidad de flujo de radiación de onda corta incidente en vatios por metro cuadrado.

El rendimiento pronosticado es igual al producto de los componentes G (genética), E (ambiente) y M (manejo de cultivo). Como métrica de desempeño se utilizó el RMSE. El modelo propuesto se evaluó con base en rendimientos descriptivos como predictivos. El rendimiento descriptivo mide que tan bien se puede explicar la variabilidad espacial y temporal del rendimiento del cultivo, mientras que el rendimiento predictivo evalúa la capacidad del modelo para predecir el rendimiento a nivel de cada condado en los próximos años. En esta investigación se plantea un modelo propio llamado GEM que es un problema de optimización no lineal, y para esto se expone un algoritmo heurístico que se resuelve mediante solucionadores de última generación usando Gurobi y Cplex [26],[27]. Se realizaron 40 experimentos para el año 2019 con información meteorológica actualizada diariamente y se logró obtener un R^2 de 0.8 y un RMSE de 22.5 lo que garantiza un buen ajuste del modelo que puede ser generalizado para cada condado de acuerdo con las características de clima, suelo y manejo. Finalmente, los autores concluyen que se obtuvieron buenos resultados con el modelo propuesto, sin embargo existen ciertas limitaciones a tener en cuenta como: el diseño del modelo está restringido al conjunto de datos de la investigación, no se puede aplicar a otros dataset a menos de que se hagan las respectivas modificaciones, además, varias variables importantes como riego, fertilización, labranza, control de enfermedades/malezas no se tuvieron en cuenta en el modelo debido a la falta de datos.

En 2020 [28], se plantea un estudio para predecir el rendimiento del maíz en África oriental y meridional (ESA). El estudio se realizó en 5 países, Etiopía, Kenia, Tanzania, Malawi y Mozambique. El objetivo de la investigación consistió en evaluar el rendimiento del maíz teniendo en cuenta diferentes sistemas de cultivo. Los sistemas de cultivo analizados fueron, la agricultura de conservación por rotación (CA Rotación), la agricultura de conservación con maíz único (CA Sole) y la agricultura intercalada (CA-Intercrop), en tierras altas y bajas. Se recopilieron datos de los niveles de producción durante 7 años en diferentes lugares del continente. Con base en este conjunto de datos se dividió el dataset en entrenamiento (80%) y testeo (20%); además se utilizó la técnica de validación cruzada con 10 folders para estimar la precisión de los modelos de ML seleccionados. Los datos fueron

clasificados en dos agroecologías (tierras altas y tierras bajas) lo que sugirió la implementación de algoritmos de ML lineales y no lineales. Los algoritmos utilizados fueron:

- Algoritmos lineales: regresión logística (LR) y análisis discriminante lineal (LDA).
- Algoritmos no lineales: K-vecinos más cercanos (KNN), árboles de clasificación y regresión (CART), Naive Bayes (NB), máquinas de soporte vectorial (SVM), entre otros.

Las métricas de desempeño que se utilizaron para evaluar los algoritmos fueron la precisión y el estadístico kappa³. Según los resultados obtenidos el algoritmo de discriminante lineal (LDA) obtuvo mayor precisión en comparación con los demás algoritmos, así mismo SVM tuvo la predicción más baja. En general los autores concluyeron que los algoritmos lineales se desempeñaron mejor en la predicción del rendimiento del maíz bajo diferentes sistemas de cultivo (LDA y LR) con respecto a los algoritmos no lineales.

También en 2020 [29], se planteó un modelo para predecir el rendimiento del cultivo de maíz en 2 condados de la república de Kenia en África (Trans-Nzoia y Nakuru) mediante el uso de datos satelitales (imágenes). En este estudio se usa una red neuronal artificial (*Artificial Neural Network*, ANN) con propagación hacia atrás con el algoritmo Levenberg-Marquardt. Para modelar el rendimiento se utilizan datos históricos entre los años 2005 y 2016 que mediante procesamiento de las imágenes y algunas características del cultivo como precipitación, temperatura, evapotranspiración, humedad del suelo e índice de vegetación de diferencia normalizada (NDVI) se construyó el dataset para entrenar el modelo de ANN. Para la selección de las características se utilizó el método boruta donde se definen las variables más importantes que se utilizarán como entrada a la red neuronal, así mismo el conjunto de datos se dividió en un 70% para entrenamiento, un 20% para validación y un 10% para testeo. El desempeño del modelo fue evaluado usando el coeficiente de determinación R^2 y el RMSE. Los resultados obtenidos muestran que las variables climáticas de temperatura máxima, temperatura mínima y la humedad del suelo fueron las variables más influyentes en el rendimiento. Se realizaron 30 iteraciones donde se obtuvo que el mejor valor de R^2 es de 0.76 y un valor de RMSE de 0.86 correspondientes a 0.038 Tn/Ha y 0.016 en los condados de Trans Nzoia y Nakuru.

En 2019 [30], se desarrollaron 4 meta modelos de aprendizaje automático para predecir el rendimiento del maíz y la pérdida de nitrógeno basados en datos del clima, prácticas de manejo y el genotipo. El objetivo principal de la investigación consistió en adaptar estos modelos en un sistema de simulación de cultivos llamado APSIM usando datos experimentales de 7 ubicaciones del oeste de EE. UU. con observaciones del rendimiento de maíz y pérdidas de nitrógeno en un periodo de 7 años. Las pérdidas de nitrógeno en cada fase del cultivo es un indicador clave del rendimiento que se obtendrá en los próximos meses. En este caso se implementaron 4 modelos de ML: LASSO Regression, Ridge Regression, Random Forests y Extreme Gradient Boosting (XGBoost). Las métricas de

³ El estadístico kappa de Cohen mide la confiabilidad entre evaluadores (a veces llamada concordancia entre observadores). El estadístico kappa varía de 0 a 1 donde 0: concordancia equivalente al azar, 0.1-0.20: ligera concordancia, 0.21-0.4: acuerdo justo, 0.41-0.6: acuerdo moderado, 0.61-0.80: acuerdo sustancial, 0.81-0.99: concordancia casi perfecta y 1 acuerdo perfecto.

desempeño que se utilizaron para evaluar el rendimiento de los modelos fueron RMSE, error cuadrático medio relativo (RRMSE), coeficiente de determinación (R^2) y error de sesgo medio (MBE) para calcular el error entre las simulaciones APSIM y las predicciones de ML.

Los resultados muestran que el mejor modelo para predecir el rendimiento fue XGBoost donde se obtuvo el valor de RMSE más bajo, mientras que el mejor modelo para calcular las pérdidas por nitrógeno fue Random Forest. Según las pruebas experimentales cada vez que se aumentaban los datos al modelo y se realizaban entrenamientos, algunos modelos de ML eran más sensibles al tamaño de los datos de entrenamiento, lo que afectaba el cálculo de las variables a predecir. Además, se logró identificar que las variables más importantes para calcular el rendimiento y las pérdidas de nitrógeno fueron la temperatura, la lluvia y la radiación. Finalmente, los autores concluyen que a pesar de que los modelos seleccionados superan a otros modelos de ML no funcionan bien en algunas áreas geográficas, lo que restringe su aplicación.

4.2 Estudios relacionados con CLR

La regresión lineal por grupos (CLR, *Clusterwise Linear Regression*) es un enfoque basado en la combinación de clustering con modelos de regresión lineales pero que también pueden extenderse a métodos no lineales. Este método es útil para investigar la relación entre predictores y respuestas escalares con variación heterogénea para diferentes subgrupos. CLR tiene como objetivo encontrar la partición de los datos en k grupos (clústeres), de modo que las regresiones lineales ajustadas a cada uno de los clústeres minimicen el error cuadrático medio general en todos los datos [31]. A continuación, se presentan algunos estudios relacionados con la aplicación del CLR en diferentes sectores.

En 2020 [32] se empleó el algoritmo CLR para la predicción de la condición del pavimento, cuya variable dependiente es el índice de condición del pavimento (PCI, *Pavement Condition Index*). CLR permite agrupar los datos simultáneamente y estimar los modelos asociados; en este estudio se propone un programa matemático generalizado y un algoritmo de solución dentro del marco de CLR. Se utilizó un conjunto de datos del departamento de Nevada EE. UU. que contiene información referente a estado y/o mantenimiento de las vías en un tiempo. Algunas de las variables del dataset son:

- age: Antigüedad del último mantenimiento realizado al tramo de pavimento,
- adt: Trafico medio diario,
- trucks: Promedio de camiones diarios,
- precip: Promedio de precipitación anual y
- min_temp, max_temp: Promedio de temperaturas mínimas y máximas al año.

La precisión de los modelos se evaluó mediante el RMSE, el RMSE normalizado (NRMSE) y los errores absolutos medios; el desempeño del modelo se comparó con modelos lineales y se concluyó que los modelos basados en CLR son más precisos.

En 2016 [33], se planteó un estudio para realizar la predicción de la disponibilidad de lluvia en Victoria (Australia). Inicialmente se analiza la predicción mediante algoritmos de

aprendizaje automático como redes neuronales artificiales, el promedio móvil integrado autorregresivo, la regresión lineal múltiple (MLR) y máquinas de soporte vectorial para métodos de regresión (SVMreg); los resultados muestran que todos los modelos utilizados hasta la fecha no son lo suficientemente precisos para predecir la lluvia. En este artículo, se estudia la inferencia de la precipitación mensual a partir de varias combinaciones de cinco variables meteorológicas: temperatura máxima y mínima, evaporación, presión de vapor y la radiación solar, donde se propone utilizar el enfoque CLR para este propósito. El conjunto de datos se creó con variables meteorológicas obtenidas mensualmente en un periodo de tiempo desde 1889 a 2014, la implementación del algoritmo se realizó en fortran y en el lenguaje estadístico R, el rendimiento de los modelos se evaluó con base en 4 métricas, el error cuadrático medio, el error absoluto medio, el error escalado absoluto medio y el coeficiente de eficiencia. Según los resultados obtenidos al aumentar el número de variables de entrada, el modelo CLR obtiene mejores predicciones, caso contrario se presente con la ANN y con SVMreg donde la predicción es menor. Los autores concluyen que CLR supera a todos los modelos en todas las ubicaciones logrando mejores predicciones, además se concluye que el algoritmo CLR es más preciso para predecir precipitaciones extremas.

De los anteriores estudios se puede evidenciar que existe un amplio interés en mejorar el rendimiento de cultivos haciendo uso de sistemas y técnicas de inteligencia computacional. Se han logrado avances importantes en el área, sin embargo, en la mayoría de los casos no se ha tenido en cuenta la agricultura específica por sitio, donde se evidencia una potencial aplicación del algoritmo CLR. Por su parte el algoritmo CLR a la fecha no se ha utilizado en temas relacionados con la agricultura, por lo cual se ve una gran oportunidad para explorar este campo y generar una solución que ayude a los agricultores de maíz en la toma de decisiones. Una de las principales limitaciones que se detectaron en el estado del arte es que los modelos propuestos no pueden ser replicables dado que no tienen en cuenta limitaciones técnicas y financieras por parte del agricultor, por ende, lo que se pretende abordar en este trabajo de investigación aparte de generar un modelo que explique la predicción del rendimiento de manera óptima, consiste en dar una solución que pueda ser replicable y viable en cuanto a tiempo y costos que lo haga asequible a los cultivadores minifundistas.

5 OBJETIVOS

5.1 Objetivo general

Adaptar una metaheurística para recomendar prácticas de manejo de los cultivos de maíz basado en un modelo CLR u otro de aprendizaje de máquina, que busque mejorar el rendimiento (Kg/Ha) de las fincas en el departamento de Córdoba (Colombia).

5.2 Objetivos específicos

1. Definir una vista minable⁴ sobre cultivos de maíz según las tres primeras fases de CRISP-DM⁵ (comprensión del negocio, compresión de datos y preparación de datos) sobre los datos suministrados por el CIAT y FENALCE, y el conocimiento previo del grupo de investigación, buscando la caracterización de las zonas utilizadas para dichos cultivos al interior del departamento de Córdoba.
2. Adaptar el enfoque CLR en las etapas de modelado y evaluación de CRISP-DM, para predecir el rendimiento de los cultivos registrados en la minable previamente definida y comparar su desempeño basado en R^2 frente a la predicción obtenida con algoritmos del estado del arte (regresión lineal, árboles de decisión, redes neuronales, XGBoost, random forest, máquinas de soporte vectorial para modelos de regresión, entre otros).
3. Adaptar las Metaheurísticas de Recocido Simulado (SA) y el Algoritmo de Optimización del Lobo Gris (GWO) basado en el Patrón de Investigación Iterativa propuesto por Pratt⁶[34] buscando definir las prácticas de manejo que permiten obtener el mejor rendimiento del cultivo de maíz usando el modelo CLR propuesto o el mejor modelo definido en el objetivo específico anterior y restricciones propias del problema.
4. Desarrollar una aplicación WEB como parte de la etapa de despliegue de CRISP-DM haciendo uso de la metodología SCRUM⁷, donde se empaquete el mejor modelo obtenido que permita a los agricultores realizar la predicción del rendimiento de sus cultivos y recomendar prácticas buscando incrementar dicho rendimiento.

6 HIPOTESIS

Con base en el planteamiento del problema y en específico la pregunta de investigación relacionada con la predicción del rendimiento de cultivos de maíz, se plantean las siguientes hipótesis:

- **H1:** “Implementar el enfoque Clusterwise (CLR) permite predecir el rendimiento del cultivo de maíz con un coeficiente de correlación (R^2) superior en un 10% en comparación con el obtenido por algoritmos de aprendizaje supervisado del estado del arte (regresión lineal, árboles de decisión, redes neuronales, XGBoost, random forest, máquinas de soporte vectorial para modelos de regresión, entre otros)”
- **H0:** “Implementar el enfoque Clusterwise (CLR) NO permite predecir el rendimiento del cultivo de maíz con un coeficiente de correlación (R^2) superior en un 10% en comparación con el obtenido por algoritmos de aprendizaje supervisado del estado del

⁴ Tabla única des-normalizada compuesta por todas variables relevantes para un problema de minería de datos.

⁵ **CRIPS-DM** (Cross Industry Standard Process for Data Mining) es una metodología para desarrollar proyectos de minería de datos compuesta por 6 fases, en donde paso a paso describe las tareas a tareas para el desarrollo del proyecto además de brindar las pautas para el correcto manejo de los riesgos, los recursos entre otros.

⁶ El **Patrón de Investigación iterativa propuesto por Pratt** es un marco iterativo que consta de 4 fases: observación de la aplicación de destino, identificación de problemas, desarrollo de la solución y testeo de las pruebas. Si en la primera iteración no se cumple con el objetivo se vuelve a ejecutar el mismo marco cuantas veces sea necesario.

⁷ **SCRUM** es un marco de trabajo ágil con un enfoque iterativo e incremental para gestionar el desarrollo de productos en el cual se pueden emplear diferentes procesos y técnicas. Es un proceso de equipo con unos roles definidos, donde el desarrollo se divide en iteraciones (Spring) y a lo largo de cada iteración se realizan una serie de eventos, que ayudan a la mitigación de riegos y la rápida adaptación a cambios.

arte (regresión lineal, árboles de decisión, redes neuronales, XGBoost, random forest, máquinas de soporte vectorial para modelos de regresión, entre otros)”

De la misma manera, con base en el planteamiento del problema y en específico con la segunda pregunta de investigación relacionada con la recomendación de prácticas de manejo (cultivo) para incrementar la producción de los cultivos de maíz haciendo uso de las metaheurísticas, se plantean las siguientes hipótesis:

- **H2:** “El algoritmo de Recocido Simulado o el Algoritmo de Optimización del Lobo Gris recomienda prácticas de manejo (cultivo) viables para un agricultor del departamento de Córdoba que permiten incrementar la productividad de un cultivo en un 10% mínimo.”
- **H0:** “NI el algoritmo de Recocido Simulado, NI el Algoritmo de Optimización del Lobo Gris recomiendan prácticas de manejo (cultivo) viables para un agricultor del departamento de Córdoba que permiten incrementar la productividad de un cultivo en un 10% mínimo.”

De acuerdo con las hipótesis H1 y H2 planteadas anteriormente se tiene que las variables independientes son: el enfoque Clusterwise y las metaheurísticas, y la variable dependiente es el rendimiento del cultivo del maíz. De esta manera se tiene que la relación entre las variables es:

x: Enfoque Clusterwise
Metaheurísticas  y: Rendimiento cultivo

Una vez identificadas las variables en la hipótesis se definen conceptual y operacionalmente para garantizar que las variables sean comprensibles, precisas y medibles. Para analizar los indicadores de la **variable rendimiento del cultivo de maíz**, se debe limitar la zona donde se ejecutará la investigación, en este caso es el departamento del Córdoba. Los indicadores del rendimiento se obtuvieron para el año 2022 teniendo en cuenta la producción kg/ha en ese departamento.

Variable	Definición Conceptual	Dimensión	Indicador
Rendimiento del cultivo del maíz	El rendimiento del maíz hace referencia al nivel de producción (Kg/Ha) que puede obtenerse de una siembra.	Rendimiento alto	>4000 kg/Ha
		Rendimiento medio	[2000 – 4000] Kg/Ha
		Rendimiento bajo	< 2000 Kg/Ha

Para el caso de la primera hipótesis H1, el desempeño del enfoque Clusterwise se mide con base en la diferencia del valor del coeficiente de correlación (R^2) del obtenido por el enfoque CLR menos el valor obtenido por el mejor algoritmo supervisado del estado del arte; en este caso se define como nivel de mejora (alta, baja o inexistente).

Variable	Definición Conceptual	Dimensión	Indicador
Enfoque CLR	El enfoque CLR es una técnica que permite dividir simultáneamente los datos en un número determinado de agrupaciones y encontrar los coeficientes de regresión para cada grupo	Mejora alta	La mejora es superior al 10%
		Mejora baja	La mejora es superior al 0% y menor o igual al 10%
		Mejora inexistente	La mejora es menor o igual al 0%.

Para el caso de la segunda hipótesis H2, las metaheurísticas se califican de acuerdo con la obtención de recomendaciones viables que puedan ser usadas en campo por parte de los agricultores y cuya diferencia en la productividad estimada frente a lo registrado en el dataset supere el 10% de lo reportado en el conjunto de datos suministrado; en este caso se define como nivel de mejora (alta, baja o inexistente).

Variable	Definición Conceptual	Dimensión	Indicador
metaheurísticas	Según Osman y Kelly (1996) define “Los procedimientos metaheurísticos son una clase de métodos aproximados que están diseñados para resolver problemas difíciles de optimización combinatoria, en los que los heurísticos clásicos no son ni efectivos ni eficientes. Los metaheurísticos proporcionan un marco general para crear nuevos algoritmos híbridos combinando diferentes conceptos derivados de la inteligencia artificial, la evolución biológica y la mecánica estadística”.	Mejora alta	La mejora es igual o superior al 10%
		Mejora baja	La mejora es superior al 0% y menor al 10%
		Mejora inexistente	La mejora es menor o igual al 0%.

7 ACTIVIDADES Y CRONOGRAMA

7.1 Actividades

Para la ejecución del proyecto se utilizará la metodología CRISP-DM que es la más utilizada en proyectos de minería de datos. Las fases de esta metodología se muestran en la Figura 1 y abarca: entendimiento del negocio, preparación de los datos, modelado, evaluación y despliegue [35]. Teniendo en cuenta que una parte del proyecto involucra la implementación de algoritmos metaheurísticos y desarrollo de una aplicación software para mostrar los principales resultados, se involucra el enfoque ágil Scrum dentro de las fases de modelado y evaluación.




Figura 1: Metodología CRISP-DM

A continuación, se describen cada una de las actividades que se realizarán en cada fase de la metodología.

Fases de entendimiento del negocio y de entendimiento de los datos

- **Actividad 1:** Entender cada una de las variables presentes en el dataset.
- **Actividad 2:** Analizar cada una de las fuentes de información suministradas, identificar claves para posteriores cruces e integración.
- **Actividad 3:** Análisis exploratorio de los datos para identificar, tipos de variables, correlaciones, entre otros.

Fase de preparación de los datos

- **Actividad 4:** Preparación de los datos a través de la generación de nuevos atributos derivados, integración de registros o transformación de valores con los atributos existentes.
- **Actividad 5:** Realizar transformaciones sintácticas de los datos sin modificar su significado.
- **Actividad 6:** Limpieza de los datos, normalización, tratamiento de valores faltantes y atípicos, entre otros.

Fase de Modelado

- **Actividad 7:** Creación de modelos de predicción basados en la vista minable y algoritmos tradicionales de machine learning como: regresión lineal, arboles de decisión, redes neuronales, XGBoost, random forest, máquinas de soporte vectorial para modelos de regresión, entre otros.
- **Actividad 8:** Usar el enfoque CLR con una implementación existente o una propuesta creada en el marco del proyecto.

- **Actividad 9:** Basada en la métrica R^2 y otras métricas de calidad, evaluar y comparar el desempeño de los algoritmos y seleccionar el mejor modelo.
- **Actividad 10:** Adaptación de las metaheurísticas SA y GWO para recomendar prácticas que busquen aumentar la productividad de los cultivos teniendo en cuenta restricciones.
- **Actividad 11:** Pruebas y mejoras a las metaheurísticas y los resultados reportados.
- **Actividad 12:** Construcción de una solución que integre todos los productos en un proceso de negocio de principio a fin. Para las actividades 8 a 11 se utilizará Scrum en lo relacionado con la implementación de algoritmos y el patrón de investigación iterativa propuesto por Pratt para orientar la definición del problema, y la construcción y evaluación de la solución.
- **Actividad 13:** Generar un plan de pruebas para probar la calidad y validez de los productos construidos.

Fase Evaluación

- **Actividad 14:** Evaluar los pasos seguidos en el proceso, definir opciones de mejora y buscar razones que expliquen los resultados obtenidos.

Fase Despliegue

En esta fase se involucra el desarrollo de una aplicación software donde se va a desplegar el mejor modelo de predicción obtenido y el uso de la metaheurística que logre mejores recomendaciones. Para el desarrollo de la aplicación se utilizará el enfoque ágil SCRUM basado en varias iteraciones (Sprints). Cada Sprint tendrá una duración de 3 semanas y se espera que al final de cada uno de ellos se tenga un entregable. En este plan se definen todos los artefactos de SCRUM para garantizar entrega continua en los tiempos establecidos. Algunas de las Historias de Usuario a desarrollar en cada sprint se describen a continuación:

Sprint 1

- Documentar todos los resultados obtenidos de los modelos.
- Definir las estructuras para la exportación de los modelos.
- Definir las características, parámetros de entrada y variables globales para las metaheurísticas utilizadas.

Criterio de Aceptación: Documentación completa y definición adecuada de las variables y estructuras de datos que recibirá la aplicación como entrada.

Sprint 2

- Diseñar la arquitectura de la aplicación software.
- Selección de tecnologías para el Frontend, Backend, otros.

Criterio de Aceptación: Validación de la Arquitectura, que cumpla con los estándares mínimos de calidad y seguridad.

Sprint 3

- Codificación de requerimientos Modulo 1
- Codificación de requerimientos Modulo N

Criterio de Aceptación: Código estructurado, organizado debidamente documentado.

Sprint 4

- Pruebas unitarias para cada módulo desarrollado.
- Documentación de todo el proceso, ejecutables, artículo de investigación, monografía, entre otros.

Criterio de Aceptación: Pruebas exitosas de rendimiento, seguridad, integración para cada uno de los módulos desarrollados

7.2 Cronograma de actividades

A continuación, en la Tabla 1 se presenta el cronograma esperado de ejecución de las fases, ciclos y etapas previamente presentadas.

8 RECURSOS, PRESUPUESTO Y FUENTES DE FINANCIACIÓN

En la Tabla 2 se resumen los recursos requeridos para el desarrollo del proyecto, así como el presupuesto y las fuentes de financiación de cada rubro. El cálculo del costo del personal docente se realizó de la siguiente forma: 3 h/s x 4 s/m x 9 m x 2.5 puntos x 18.825 \$/punto x 1 director y el del personal estudiante así: 40 h/s x 4 s/m x 9 m x 1.5 puntos x 18.825\$/punto x 1 estudiante. El valor del punto estimado para 2023 fue de \$18.825 que corresponde al valor del punto en 2022 incrementado en el IPC del año 2022 en Colombia más 1.5% (\$16.441 incrementado el 14,5%).

Tabla 1: Cronograma de actividades

FASE 1: ENTENDIMIENTO DEL NEGOCIO									
ACTIVIDAD	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9
1									
2									
3									
FASE 2: PREPARACIÓN DE LOS DATOS									
ACTIVIDAD	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9
4									
5									
6									
FASE 3: MODELADO									
ACTIVIDAD	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9
7									
8									
9									
10									
11									
12									
13									
FASE 4: EVALUACIÓN									
ACTIVIDAD	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9
14									
FASE 5: DESPLIEGUE									
Plan Despliegue	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9
Sprint 1									
Sprint 2									
Sprint 3									
Sprint 4									
Articulos									
Anexos									
Monografia									

Tabla 2: Presupuesto del proyecto

Rubros	Fuentes		
	Estudiante	FIET-Sistemas	TOTAL
Personal	\$ 40.662.000	\$ 3.388.500	\$ 44.050.500
Equipo	\$ 2.000.000	\$ 500.000	\$ 2.500.000
Software	\$ 0	\$ 0	\$ 0
Pasantía	\$ 3.000.000	\$ 2.000.000	\$ 5.000.000
Bibliografía	\$ 0	\$ 180.000	\$ 180.000
Materiales	\$ 380.000	\$ 0	\$ 380.000
Publicaciones	\$ 400.000	\$ 0	\$ 400.000
Comunicaciones		\$ 170.000	\$ 170.000
Otros	\$ 576.000	\$ 0	\$ 576.000
TOTAL	\$ 47.018.000	\$ 6.238.500	\$ 53.256.500

9 CONDICIONES DE ENTREGA

Al culminar la presente investigación se obtendrán los siguientes productos:

1. **Monografía con el resumen del proyecto:** este documento contendrá el estado del arte referente a trabajos de investigación realizados sobre el sector agrario, además de trabajos donde se ha utilizado el enfoque clusterwise. Se presentará en detalle la propuesta de adaptación del enfoque clusterwise para ser usada en cultivos de maíz, finalmente se mostrará los resultados de la evaluación de los algoritmos y su comparación. Se espera estructurar la monografía de la siguiente manera: 1) Introducción (Problema, Justificación, Objetivos y Resultados); 2) Contexto teórico y estado del arte; 3) Clusterwise en cultivos de maíz; 4) Evaluación y comparación de algoritmos para Clusterwise; 5) Proceso de optimización mediante metaheurísticas; 6) Conclusiones y trabajo futuro y 7) Referencias y anexos.
2. **Dos artículos:** para dar a conocer las conclusiones del trabajo, el primero como resultado de la adaptación del enfoque clusterwise y el segundo con los resultados del proceso de optimización. Para su elaboración se seguirá el formato de la IEEE o el requerido por la revista/evento.
3. **Pipeline:** Hace referencia a todo el flujo que sufren los datos desde la ingesta hasta la construcción de la vista minable, que será utilizada por los modelos de machine learning y su paso por la construcción, evaluación y despliegue del modelo. En este pipeline se orquesta todo el flujo y transformaciones que sufren los datos hasta el modelado con el objetivo que el experimento pueda ser replicado, sin importar la ubicación geográfica de los cultivos, teniendo en cuenta diferentes variables de clima, suelo, prácticas de manejo, entre otros.
4. **Código fuente:** del software desarrollado en el proyecto con su respectiva documentación como anexo de la monografía.

10 REFERENCIAS BIBLIOGRÁFICAS

- [1] Ripusudan L, Granados. G, Lafitte. H, “El maíz en los trópicos: Mejoramiento y producción.” Available: <https://www.fao.org/3/x7650s/x7650s02.htm> (accessed Nov. 27, 2022).
- [2] S. García. Lara and S. O. Serna. Saldivar, “Corn History and Culture,” *Corn Chem. Technol. Third Ed.*, pp. 1–18, Jan. 2019
- [3] Agropinos insumos para el campo, “La importancia del cultivo del maíz en Colombia” Available:<https://www.agropinos.com/blog/importancia-del-cultivo-de-maiz-en-colombia> (accessed Mar. 13, 2023).
- [4] Fenalce, “Estadísticas - Fenalce.” Available: <https://fenalce.co/estadisticas/> (accessed Nov. 28, 2022).
- [5] Revista Virtualpro, “Identifican factores que afectan rendimiento del maíz.” Available: <https://www.virtualpro.co/noticias/identifican-factores-que-afectan-rendimiento-del-maiz> (accessed Nov. 28, 2022).
- [6] M. O. Gokalp, K. Kayabay, M. A. Akyol, P. E. Eren, and A. Kocyigit, “Big data for Industry 4.0: A conceptual framework,” in *International Conference on Computational Science and Computational Intelligence (CSCI)*, Las Vegas, NV, USA, pp. 431–434, Mar. 2017.
- [7] L. Feng, Y. Wang, Z. Zhang, and Q. Du, “Geographically and temporally weighted neural network for winter wheat yield prediction,” *Remote Sensing of Environment.*, vol. 262, pp. 112514, Sep. 2021.
- [8] T. Pede, G. Mountrakis, and S. B. Shaw, “Improving corn yield prediction across the US Corn Belt by replacing air temperature with daily MODIS land surface temperature,” *Agricultural and Forest Meteorology*, vol. 276–277, pp. 107615, Oct. 2019.
- [9] J. Han, Z. Zhang, J. Cao, Y. Luo, L. Zhang, Z. Li, J. Zhang, “Prediction of Winter Wheat Yield Based on Multi-Source Data and Machine Learning in China,” *Remote Sensing*, vol. 12, no. 2, p. 236, Jan. 2020.
- [10] R. E. Plant, “Site-specific management: The application of information technology to crop production,” *Computers and Electronics in Agriculture*, vol. 30, no. 1–3, pp. 9–29, Feb. 2001.
- [11] P. S. Vani and S. Rathi, “Improved data clustering methods and integrated A-FP algorithm for crop yield prediction,” *Distributed and Parallel Databases*, vol. 41, no. 1, pp. 117–131, Jun. 2021.
- [12] J. Rodriguez, A. M. González, F. R. Leiva, L. Guerrero, “Respuesta del cultivo de maíz (zea mays l.) a la fertilización por sitio específico en suelos de la Sabana de Bogotá,” *Agronomía Colombiana*, vol. 26, no. 2, pp. 1-6, Dec. 2008.
- [13] H. Burdett and C. Wellen, “Statistical and machine learning methods for crop yield prediction in the context of precision agriculture,” *Precision Agriculture*, vol. 23, no. 5, pp. 1553–1574, Oct. 2022.
- [14] M. Shahhosseini, G. Hu, I. Huber, and S. V. Archontoulis, “Coupling machine learning and crop modeling improves crop yield prediction in the US Corn Belt,” *Scientific Reports*, vol. 11, no. 1, pp. 1–15, Jan. 2021.
- [15] Anacona. F, Cobos. C, and Mendoza. M, “Algoritmo greedy para predecir el índice de servicio de pavimento basado en agrupación y regresión lineal,” *Investigación e Innovación en Ingenierías*, vol. 8, no. 3, pp. 119–134, Nov. 2020.
- [16] B. Suman and P. Kumar, “A survey of simulated annealing as a tool for single and multiobjective optimization,” *Journal of the Operational Research Society*, vol. 57, no. 10, pp. 1143–1160, Oct. 2006
- [17] A. H. Halim, I. Ismail, and S. Das, “Performance assessment of the metaheuristic optimization algorithms: an exhaustive review,” *Artificial Intelligence Review*, vol. 54, no. 3, pp. 2323–2409, Mar. 2021.
- [18] S. Mirjalili, S. M. Mirjalili, and A. Lewis, “Grey Wolf Optimizer,” *Advances in*

- Engineering Software*, vol. 69, pp. 46–61, Mar. 2014.
- [19] J. S. Wang and S. X. Li, “An Improved Grey Wolf Optimizer Based on Differential Evolution and Elimination Mechanism,” *Scientific Reports*, vol. 9, no. 1, pp. 1–21, May 2019.
- [20] Centro Internacional de Agricultura Tropical (CIAT), “Boletín Informativo Maíz para Colombia 2030.” Available: <https://repository.cimmyt.org/handle/10883/20218>.
- [21] S. N. Khan, D. Li, M. Maimaitijiang, “A Geographically Weighted Random Forest Approach to Predict Corn Yield in the US Corn Belt,” *Remote Sensing*, vol. 14, no. 12, p. 2843, Jun. 2022.
- [22] T. Conradt, “Choosing multiple linear regressions for weather-based crop yield prediction with ABSOLUT v1.2 applied to the districts of Germany,” *International Journal of Biometeorology*, vol. 66, no. 11, pp. 2287–2300, Nov. 2022.
- [23] L. Wang, “Data Driven Explanation of Temporal and Spatial Variability of Maize Yield in the United States,” *Front. Plant Sci.*, vol. 12, p. 1877, Sep. 2021.
- [24] United States Department of Agriculture, “USDA/NASS QuickStats Ad-hoc Query Tool.” <https://quickstats.nass.usda.gov/> (accessed Nov. 19, 2022).
- [25] EarthData, “Daymet: Daily Surface Weather Data on a 1-km Grid for North America, Version 3.” Available: https://daac.ornl.gov/DAYMET/guides/Daymet_V3_CFMosaics.html (accessed Nov. 19, 2022).
- [26] Gurobi Optimization, “The Leader in Decision Intelligence Technology - Gurobi Optimization.” Available: <https://www.gurobi.com/> (accessed Nov. 20, 2022).
- [27] IBM, Ibm Ilog Cplex Optimizer, Available: <https://www.ibm.com/products/ilog-cplex-optimization-studio/cplex-optimizer> (accessed Nov. 20, 2022).
- [28] W. Mupangwa, L. Chipindu, I. Nyagumbo, S. Mkuhlani, and G. Sisito, “Evaluating machine learning algorithms for predicting maize yield under conservation agriculture in Eastern and Southern Africa,” *SN Applied Sciences*, vol. 2, no. 5, pp. 1–14, May 2020.
- [29] J. I. Mwaura and B. K. Kenduiwo, “County level maize yield estimation using artificial neural network,” *Modeling Earth Systems and Environment*, vol. 7, no. 3, pp. 1417–1424, Aug. 2020.
- [30] M. Shahhosseini, R. A. Martinez. Fera, G. Hu, and S. V. Archontoulis, “Maize yield and nitrate loss prediction with machine learning algorithms,” *Environmental Research Letters*, vol. 14, no. 12, p. 124026, Dec. 2019.
- [31] T. Li, X. Song, Y. Zhang, H. Zhu, and Z. Zhu, “Clusterwise functional linear regression models,” *Computational Statistics & Data Analysis.*, vol. 158, pp. 107192, Jun. 2021.
- [32] M. Khadka, A. Paz, and A. Singh, “Generalised clusterwise regression for simultaneous estimation of optimal pavement clusters and performance models,” *International Journal of Pavement Engineering*, vol. 21, no. 9, pp. 1122–1134, Sep. 2018.
- [33] A. M. Bagirov, A. Mahmood, and A. Barton, “Prediction of monthly rainfall in Victoria, Australia: Clusterwise linear regression approach,” *Atmospheric Research*, vol. 188, pp. 20–29, May 2017.
- [34] K. S. Pratt and H. R. Bright, “Design Patterns for Research Methods: Iterative Field Research”, Accessed: Feb. 19, 2023. [Online]. Available: www.aaai.org
- [35] IBM, “Conceptos básicos de ayuda de CRISP-DM - Documentación de IBM.” Available: <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview> (accessed Dec. 12, 2022).

UNIVERSIDAD DEL CAUCA
FACULTAD DE INGENIERÍA ELECTRÓNICA Y TELECOMUNICACIONES
ACTA DE ACUERDO SOBRE LA PROPIEDAD INTELECTUAL DE LA TESIS DE
MAESTRIA Y DOCTORADO

En atención al acuerdo del Honorable Consejo Superior de la Universidad del Cauca, número 008 del 23 de febrero de 1999, donde se estipula todo lo concerniente a la producción intelectual en la institución, los abajo firmantes, reunidos el día ____ del mes de _____ de _____ en el salón del Consejo de Facultad, acordamos las siguientes condiciones para el desarrollo y posible usufructo del siguiente proyecto.

Materia del acuerdo: Trabajo de grado de Maestría para optar el título de Magister en Computación.

Título de la Tesis: Optimización del Rendimiento de los cultivos de Maíz basado en Clusterwise Linear Regression y Metaheurísticas.

Objetivo de la Tesis: Adaptar una metaheurística para recomendar prácticas de manejo de los cultivos de maíz basado en un modelo CLR u otro de aprendizaje de máquina, que busque mejorar el rendimiento (Kg/Ha) de las fincas en el departamento de Córdoba (Colombia).

Duración de la Tesis: 9 meses

Cronograma de actividades: El programa de actividades y cronograma del trabajo de grado están estipulados en el anteproyecto.

Término de vinculación de cada partícipe en el mismo: 9 meses

Organismo financiador: -----, naturaleza y cuantía de sus aportes -----, porcentaje de los costos del trabajo -----.

Los participantes de la Tesis, el estudiante de Maestría en Computación Germán Homero Morán Figueroa, identificado con la cédula de ciudadanía número 1.086.106.976, a quien en adelante se le llamará "estudiante", el ingeniero Carlos Alberto Cobos Lozada en calidad de director del trabajo de grado, identificado con la cédula de ciudadanía 91.154.963, a quien en adelante se le llamará "docente", y la Universidad del Cauca, representada por el Decano de la FIET, manifiestan que:

1.- La idea original del proyecto es del ingeniero Carlos Alberto Cobos Lozada quien la propuso y presentó al Grupo de I+D en Tecnologías de la Información (GTI), que la aceptó como tema para el proyecto de grado en referencia.

2.- La idea mencionada fue acogida por el estudiante como proyecto para obtener el grado de Magister en Computación, quien la desarrollará bajo la dirección del docente.

3.- Los derechos intelectuales y morales corresponden al docente y al estudiante.

4.- Los derechos patrimoniales corresponden al docente, a los estudiantes y a la Universidad del Cauca por partes iguales y continuarán vigentes, aún después de la desvinculación de alguna de las partes de la Universidad.

5.- Los participantes se comprometen a cumplir con todas las condiciones de tiempo, recursos, infraestructura, dirección, asesoría, establecidas en el anteproyecto, a estudiar, analizar, documentar y hacer acta de cambios aprobados por el Consejo de Facultad, durante el desarrollo del proyecto, los cuales entran a formar parte de las condiciones generales.


6.- El estudiante se compromete a restituir en efectivo y de manera inmediata a la Universidad los aportes recibidos y los pagos hechos por la Institución a terceros por servicios o equipos, si el comité de Postgrados, previo concepto del Comité de Maestría respectivo declara suspendido el proyecto por incumplimiento del cronograma o de las demás obligaciones contraídas por los estudiantes; y en cualquier caso de suspensión, la obligación de devolver en el estado en que les fueron proporcionados y de manera inmediata, los equipos de laboratorio, de cómputo y demás bienes suministrados por la Universidad para la realización del proyecto.


7.- El docente y el estudiante se comprometen a dar crédito a la Universidad y de hacer mención del Fondo de Fomento de Investigación en caso de existir, en los informes de avance y de resultados, y en registro de éstos, cuando ha habido financiación de la Universidad o del Fondo.

8.- Cuando por razones de incumplimiento, legalmente comprobadas, de las condiciones de desarrollo planteadas en el anteproyecto y sus modificaciones, el participante deba ser excluido del proyecto, los derechos aquí establecidos concluyen para él. Además, se tendrán en cuenta los principios establecidos en el reglamento del programa y el acuerdo 035 de 1992 vigente de la Universidad del Cauca en lo concerniente a la cancelación y la pérdida del derecho a continuar estudios.

9.- El documento del anteproyecto y las actas de modificaciones si las hubiere, forman parte integral de la presente acta.

10.- Los aspectos no contemplados en la presente acta serán definidos en los términos del acuerdo 008 del 23 de febrero de 1999 expedido por el Consejo Superior de la Universidad del Cauca, del cual los participantes del acuerdo aseguran tener pleno conocimiento.


Germán Homero Morán Figueroa
C.C. 1.086.106.976


CARLOS ALBERTO COBOS LOZADA
T.P. 825560575570
INGENIERO DE SISTEMAS - UIS
DIRECCIÓN INGENIERÍA DE SISTEMAS
Y COMPUTACIÓN
P.B. UNIVERSIDAD NACIONAL
Carlos Alberto Cobos Lozada
C.C. 91.154.963

Alejandro Toledo Tovar (Decano FIET)
C.C. 76.321.704